PROYECTO LINKEDIN

INTEGRANTES
GABRIEL BERMAR
FELIPE MONSALVE
MAURICIO ZENTENO

BIG DATA - 002D

INTRODUCCIÓN, PROBLEMA Y SOLUCIÓN

- 1. Introducción
- Red profesional líder mundial.
- +410 millones de miembros en +200 países.
- Conexión y éxito profesional.

- 2. La Problemática
- Crecimiento masivo: de 2.700 a 410 millones de usuarios.
- Rastreo de cada interacción (clics, visitas, mensajes).
- Necesidad de insights en tiempo real sin perder rendimiento.

- 3. La Solución
- Implementación de Ecosistema Big Data.
- Arquitectura Lambda: Análisis histórico (Batch) + Tiempo Real (Streaming).
- Algoritmos de Machine Learning ("Gente que podrías conocer").

¿POR QUE BIG DATA?

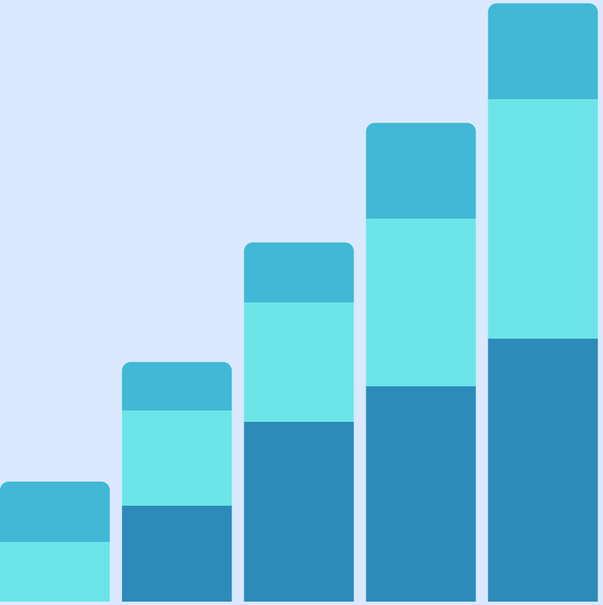

Dimensiónes	Descripción en LinkedIn	Justificación Big Data
Volumen	+410 millones de usuarios y millones de interacciones diarias	Supera la capacidad de bases de datos tradicionales
Velocidad	Procesamiento en tiempo real (notificaciones, sugerencias, actividad)	Requiere baja latencia y análisis inmediato
Variedad	Datos estructurados y no estructurados (perfiles, clics, logs, contactos, redes externas)	Necesita tecnologías flexibles como NoSQL y Data Lake

OBJETIVOS TÉCNICOS DEL PROYECTO.

DuocUC

1. Escalabilidad y Alta Disponibilidad

- Soportar crecimiento lineal de usuarios (+410M).
- Múltiples centros de datos para evitar caídas del servicio.

2. Procesamiento en Tiempo Real (Streaming)

- Reducir latencia entre generación del dato y visualización.
- Mostrar actualizaciones instantáneas al usuario.

3. Modelos de Machine Learning

- Automatizar personalización de la plataforma.
- Mejorar algoritmos como "Gente que podrías conocer".

PROPUESTA DE ARQUITECTURA: MODELO LAMBDA

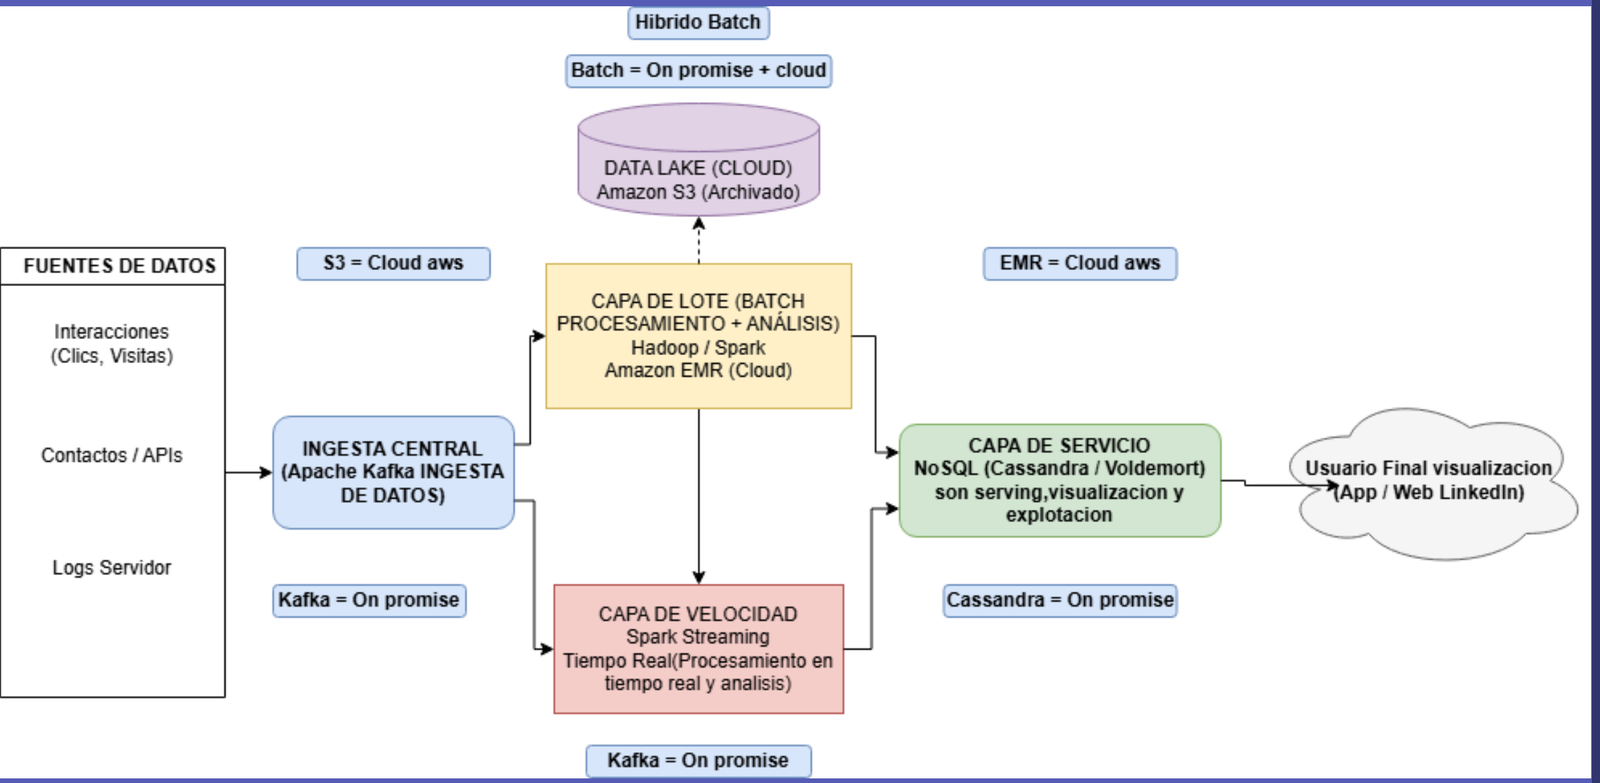

- Capa de Lote (Batch): Gestión de datos maestros y entrenamiento de modelos de Machine Learning (Hadoop).
- Capa de Velocidad (Speed): Procesamiento de flujos recientes (clics, vistas) con baja latencia (Kafka/Spark).
- Capa de Servicio (Serving): Entrega de resultados y recomendaciones actualizadas al usuario (NoSQL).

ARQUITECTURA LAMBDA

HERRAMIENTAS DE LA ARQUITECTURA

On-Premise

cassandra

hadoop

kafka

Spark

BASE DE DATOS

Cloud

Amazon S3

CICLO DE VIDA DE LOS DATOS

1 Captura e Ingesta

- Rastreo continuo de clics, visitas y mensajes.
- Herramienta principal: Apache Kafka.

2 Almacenamiento

- Ecosistema distribuido para datos masivos e históricos.
- Herramienta principal: Hadoop (HDFS) y NoSQL.

3 Procesamiento y Análisis

- Creación de algoritmos ML y análisis de redes profesionales.
- Herramienta principal: Spark.

4 Archivado y Eliminación

- Retención por cumplimiento normativo o borrado seguro.
- Herramienta principal: Amazon S3 (Nube).

GOBIERNO DE DATOS: PILARES Y DESAFÍOS ÉTICOS

1. Privacidad y Transparencia

- Uso ético de la información personal.
- Caso Real: Demanda por 13 millones USD (2015) por falta de claridad en el uso de correos.

2. Calidad del Dato

- Filtrado de información errónea para no afectar el Machine Learning.

3. Seguridad

- Encriptación y controles de acceso estrictos en clústeres Hadoop.

4. Disponibilidad

- Arquitectura redundante para garantizar acceso 24/7 sin pérdida de datos.

CONCLUSIONES DE ESTA ETAPA DE ANÁLISIS

1. Big Data como Motor de Negocio
   - Los datos no son solo soporte tecnológico; son el núcleo que permite a LinkedIn monetizar y crecer continuamente.

2. Eficiencia de la Arquitectura Híbrida
   - El Modelo Lambda (Batch + Streaming) demuestra ser la solución óptima para entregar personalización masiva sin perder velocidad.

3. Ética como Requisito Crítico
   - La privacidad y el gobierno de datos son obligaciones. Sin la confianza del usuario, el ecosistema colapsa (Ej: Caso 2015).