Big Data

BIY7131-002D

Duoc UC San Bernardo

Estrategias de Big Data para la Optimización de Redes Profesionales a Gran Escala: Análisis de SoftTech Solutions

13/04/2026

ÍNDICE DE CONTENIDO

1. Introducción **2**
2. Justificación del Proyecto: ¿Por qué SoftTech Solutions es Big Data? **2**
2.1.Contexto Organizacional y Necesidad de Negocio 2
2.2. Análisis de las 3Vs en el ecosistema de SoftTech Solutions (Volumen, Velocidad y Variedad) 3
Tabla Consolidada: Justificación Técnica de Big Data en SoftTech Solutions 3
3. Objetivos Técnicos del Proyecto **4**
3.1. Escalabilidad y Alta Disponibilidad de Datos 4
3.2. Optimización del Procesamiento en Tiempo Real (Streaming) 4
3.3. Integración de Modelos de Machine Learning para Sugerencias 4
4. Propuesta de Arquitectura y Herramientas **4**
4.1. Análisis de la Arquitectura de Referencia (Lambda vs. Kappa) 5
4.2. Selección de Herramientas On-Premise (Hadoop, Kafka, Spark) 5
4.3. Evaluación de Componentes Cloud (S3, Redshift, EMR) 5
4.4. Justificación de Herramientas Excluidas 5
4.5. Interacción entre capas y herramientas 6
5. Ciclo de Vida del Dato y Gobierno de Datos **6**
5.1. Fases del Ciclo de Vida: Desde la Ingesta hasta el Archivamiento 6
5.2. Estrategias de Gobierno de Datos y Gobernanza: Seguridad, Calidad y Disponibilidad 7
6. Análisis de la Problemática vs. Arquitectura Seleccionada **7**
6.1. Elementos Requeridos y No Requeridos en el flujo de SoftTech Solutions 7
6.2. Identificación de Necesidades Batch vs. Real-Time 8
6.3. Beneficios de la Arquitectura Aplicada según sus Aspectos Característicos 8
7. Conclusiones **9**
8. Anexos y Bibliografía **9**

1. Introducción

SoftTech Solutions se posiciona actualmente como la red social profesional más grande del mundo, conectando a más de 410 millones de miembros en más de 200 países. Desde su creación en 2003, su misión ha sido facilitar la productividad y el éxito de los profesionales mediante la creación de redes de contacto estratégicas.

En este contexto, el Big Data no es solo un componente de soporte, sino que constituye el núcleo de sus operaciones y la toma de decisiones. El presente informe detalla cómo SoftTech Solutions utiliza infraestructuras de alta escalabilidad, como Hadoop y tecnologías de procesamiento de flujos , para transformar una montaña de datos brutos en productos impulsados por datos (data-driven). A través del análisis de este caso, se justificará por qué es un proyecto de Big Data, se propondrá una arquitectura técnica basada en las necesidades de la industria y se establecerán prácticas de gobierno de datos esenciales para garantizar la seguridad y calidad de la información.

2. Justificación del Proyecto: ¿Por qué SoftTech Solutions es Big Data?

El proyecto de SoftTech Solutions no es simplemente una base de datos de currículums; es un ecosistema de datos masivos que cumple con las características fundamentales para ser clasificado como un proyecto de Big Data.

2.1.Contexto Organizacional y Necesidad de Negocio.

Contexto Organizacional: La competición en el sector de las redes sociales es más dura que nunca; lo que es interesante un año puede no serlo al siguiente. Para mantener su valor (tanto en la versión gratuita como premium) y sostener sus ingresos que superan los 700 millones de dólares trimestrales, SoftTech Solutions depende de que los profesionales encuentren utilidad diaria en la plataforma.

Problemática Principal: La organización se enfrenta al desafío técnico y comercial de procesar la actividad de cientos de millones de usuarios simultáneamente. El problema radica en que SoftTech Solutions rastrea cada movimiento: cada clic, cada visita a una página y cada interacción. Con más de 410 millones de miembros, esto genera una "montaña de datos" masiva que los sistemas tradicionales no pueden gestionar de forma económica ni rápida. Si la plataforma no es capaz de procesar este comportamiento para ofrecer sugerencias personalizadas o anuncios efectivos de manera inmediata, pierde relevancia frente a la competencia, afectando directamente su modelo de monetización (publicidad y suscripciones premium).

Para lograr la flexibilidad y escalabilidad requerida frente a este problema, el uso de tecnología Cloud y ecosistemas distribuidos se vuelve una pieza clave de la solución.

2.2. Análisis de las 3Vs en el ecosistema de SoftTech Solutions (Volumen, Velocidad y Variedad).

Para dar solución a la problemática de negocio descrita y cumplir con los indicadores de logro, desglosamos las dimensiones principales que justifican el uso de tecnologías de Big Data:

- **Volumen:** La plataforma gestiona datos de más de 410 millones de miembros en más de 200 países. El sistema back-end de SoftTech Solutions debe procesar millones de búsquedas por segundo y servir decenas de miles de páginas web cada segundo.
- **Variedad:** SoftTech Solutions recolecta y procesa una gran diversidad de tipos de datos, incluyendo datos estructurados (tablas de bases de datos, perfiles de usuario) y no estructurados (clics de navegación, registros de visitas, interacciones, contactos de correo electrónico y datos extraídos de otras redes sociales como Twitter).
- **Velocidad:** El sitio utiliza tecnología de procesamiento de flujos (Streaming) para garantizar que la información mostrada (noticias, nuevos empleos, quién vio tu perfil) esté actualizada en tiempo real. Esta inmediatez permite que la información sugerida por SoftTech Solutions guarde una relación directa y precisa con la navegación que realiza el usuario en ese instante (por ejemplo, los nuevos contactos que hace, las empresas que busca o los posteos específicos que revisa).

Tabla Consolidada: Justificación Técnica de Big Data en SoftTech Solutions

Esta tabla resume por qué este caso requiere herramientas de Big Data frente a soluciones tradicionales:

Dimensión	Detalle del Caso SoftTech Solutions	Justificación Técnica (Big Data)
Volumen	+410 millones de usuarios y millones de búsquedas por segundo.	Excede la capacidad de almacenamiento y procesamiento de bases de datos relacionales tradicionales.
Variedad	Mezcla de logs de clics, correos, perfiles profesionales y datos de Twitter.	Requiere sistemas capaces de manejar datos no estructurados y semi-estructurados (NoSQL/Data Lake).
Velocidad	Procesamiento de flujos para mostrar actualizaciones instantáneas **basadas en la navegación actual del usuario (contactos, posteos revisados).**	Necesita latencia mínima para análisis en tiempo real (Streaming) para reaccionar a las acciones del usuario al instante, superando al procesamiento por lotes (Batch).
Valor	Ingresos trimestrales superiores a 700 millones USD basados en insights de datos.	El análisis masivo se traduce directamente en éxito financiero y ventaja competitiva.

3. Objetivos Técnicos del Proyecto

Para que SoftTech Solutions mantenga su operatividad y ventaja competitiva, la infraestructura de datos debe cumplir con objetivos técnicos específicos que permitan transformar la "montaña de datos" en información accionable.

3.1. Escalabilidad y Alta Disponibilidad de Datos.

El sistema debe ser capaz de crecer de forma lineal para soportar el aumento constante de usuarios (más de 410 millones actualmente) sin degradar el rendimiento.

- **Alta Disponibilidad:** Implementar centros de datos múltiples para garantizar que el servicio no se interrumpa ante fallos en componentes individuales.
- **Escalabilidad:** Utilizar sistemas como Hadoop que permiten procesar volúmenes masivos mediante la distribución de tareas en miles de máquinas.

3.2. Optimización del Procesamiento en Tiempo Real (Streaming).

Uno de los pilares técnicos es reducir la latencia entre la generación del dato y su visualización.

- **Análisis Inmediato:** Transmitir datos directamente desde la fuente (como la actividad del usuario en vivo) para mostrar actualizaciones de red y empleo de forma instantánea.
- **Eficiencia en el Flujo:** Utilizar tecnologías de procesamiento de flujos para acelerar el procedimiento analítico sin depender exclusivamente de bases de datos tradicionales.

3.3. Integración de Modelos de Machine Learning para Sugerencias.

El objetivo técnico es automatizar la personalización de la plataforma mediante algoritmos avanzados.

- **Mejora de Algoritmos:** Aplicar aprendizaje automático para refinar las sugerencias de "Gente que podrías conocer", priorizando las conexiones con las que el usuario interactúa más frecuentemente.
- **Sistemas de Recomendación:** Desarrollar modelos predictivos que analicen factores como la trayectoria laboral y las conexiones compartidas para construir redes de contactos más apropiadas.

4. Propuesta de Arquitectura y Herramientas

Para abordar la complejidad de SoftTech Solutions , se propone una **Arquitectura de Referencia Lambda**. Esta elección se fundamenta en la necesidad de equilibrar el procesamiento de grandes volúmenes de datos históricos con la entrega de resultados en tiempo real con baja latencia.

Para dar cumplimiento a las exigencias técnicas del ciclo de vida del dato, el modelo integra las capas estándar de Big Data bajo un **enfoque híbrido**. Como se detalla en el diagrama a continuación, el núcleo del flujo de datos se mantiene **On-Premise** (utilizando Kafka para la ingesta, Hadoop/Spark para almacenamiento y procesamiento, y Cassandra para la explotación), lo que otorga máximo control. Al mismo tiempo, este entorno local se relaciona y complementa directamente con servicios **Cloud de AWS** (Amazon S3 como Data Lake y EMR para análisis distribuido) logrando escalabilidad y elasticidad bajo demanda.

Diagrama

4.1. Análisis de la Arquitectura de Referencia (Lambda vs. Kappa).

La arquitectura Lambda se divide en tres capas que utilizaremos de la siguiente manera:

- **Capa de Lote (Batch Layer):** Gestiona los datos maestros y calcula vistas pre-computadas utilizando **Hadoop**. Aquí se procesan los perfiles y conexiones para entrenar los modelos de Machine Learning.
- **Capa de Velocidad (Speed Layer):** Procesa los flujos de datos recientes (clics, visualizaciones) mediante **Apache Kafka**, compensando la latencia de la capa de lote.
- **Capa de Servicio (Serving Layer):** Expone las vistas para que los usuarios vean sus recomendaciones actualizadas de inmediato.

4.2. Selección de Herramientas On-Premise (Hadoop, Kafka, Spark).

Para un control total de la infraestructura (siguiendo los conceptos de la Clase 3), se seleccionan:

1. **Apache Kafka:** Para la ingesta y transporte de flujos de datos en tiempo real.
2. **Hadoop (HDFS/MapReduce):** Para el almacenamiento masivo y procesamiento por lotes de la "montaña de datos".
3. **Apache Spark:** Para el procesamiento analítico rápido, tanto en lote como en streaming.
4. **Java/Scala:** Como lenguajes base para el desarrollo de los microservicios de la plataforma.
5. **Bases de Datos NoSQL (Apache Cassandra / HBase):** Utilizadas en la Capa de Servicio para almacenar las vistas procesadas, garantizando lecturas ultrarrápidas y alta disponibilidad.

4.3. Evaluación de Componentes Cloud (S3, Redshift, EMR).

Siguiendo la tendencia de modernización, se propone integrar componentes de **AWS** para mejorar la elasticidad:

- **Amazon S3:** Como Data Lake para almacenamiento de respaldo de bajo costo.
- **Amazon EMR:** Para levantar clusters de Hadoop/Spark de forma rápida cuando la demanda de procesamiento aumente.

Se integran dos componentes de AWS: Amazon S3 como Data Lake y Amazon EMR para clusters bajo demanda, complementando la infraestructura on-premise compuesta por Hadoop, Kafka, Spark, Cassandra y HBase.

4.4. Justificación de Herramientas Excluidas.

- **Bases de datos Relacionales Tradicionales (para analítica):** Se excluyen como almacenamiento principal de Big Data debido a su incapacidad de escalar horizontalmente ante millones de búsquedas por segundo.
- **Arquitectura Kappa:** Se excluye debido a que SoftTech Solutions requiere un análisis profundo de datos históricos muy antiguos (años de trayectoria profesional), algo que la capa de lote de Lambda maneja de forma más robusta.

En conclusión, cada herramienta mencionada cumple un rol específico y complementario dentro de la arquitectura, asegurando que el dato fluya eficientemente desde su captura hasta el usuario final sin cuellos de botella.

4.5. Interacción entre capas y herramientas.

Etapa	Herramienta	Interacción
Ingesta	Apache Kafka	Recibe datos desde las fuentes y los distribuye simultáneamente a Batch y Speed
Batch (Procesamiento histórico)	Hadoop / Spark / EMR	Procesa grandes volúmenes desde S3 y genera resultados analíticos
Speed (Tiempo real)	Spark Streaming	Procesa datos en tiempo real desde Kafka para respuestas inmediatas
Almacenamiento	Amazon S3	Guarda datos históricos que luego son usados por Batch
Serving Layer	Cassandra	Recibe resultados de Batch y Speed y los unifica para consultas rápidas
Visualización	App/Web SoftTech Solutions	Consulta datos desde Cassandra para mostrar resultados al usuario

5. Ciclo de Vida del Dato y Gobierno de Datos

La gestión adecuada de la información es un pilar crítico para SoftTech Solutions , no solo para optimizar el rendimiento técnico, sino para mantener la confianza de sus usuarios y cumplir con normativas legales.

5.1. Fases del Ciclo de Vida: Desde la Ingesta hasta el Archivamiento.

Para asegurar un flujo de datos eficiente y ordenado de principio a fin, la plataforma implementa las siguientes fases. Para administrar este ciclo de vida completo, se utilizan herramientas de orquestación como **Apache Airflow** (que automatiza el paso de los datos de una fase a otra) y **Apache Atlas** (para la trazabilidad y catalogación de metadatos):

1. **Captura e Ingesta:** La plataforma sigue el rastro de cada movimiento que sus usuarios realizan en el sitio (clics, visitas, mensajes) canalizando esta información en tiempo real a través de **Apache Kafka**.
2. **Almacenamiento:** Los datos recolectados se almacenan utilizando infraestructuras de alta escalabilidad, donde **Hadoop (HDFS)** conforma el núcleo del sistema, apoyado por bases de datos como Oracle y MySQL.
3. **Procesamiento y Análisis:** Los científicos de datos utilizan herramientas como MapReduce, Pig y Hive **exclusivamente para la limpieza, transformación y preparación de los datos (ETL)**. Posteriormente, para entrenar, ejecutar y administrar los **algoritmos de aprendizaje automático** que mejoran las sugerencias a los usuarios, se emplean frameworks especializados como **Apache Spark (Spark MLlib)** en el entorno On-Premise, y servicios como **Amazon SageMaker** si se requiere elasticidad en la nube.
4. **Archivado y Eliminación (Políticas de Retención):** El archivado se automatiza mediante herramientas como las **Políticas de Ciclo de Vida (Lifecycle Policies) de Amazon S3**. En el caso de SoftTech Solutions , las políticas de retención y eliminación aplicadas para proteger a los usuarios son:
    - **Datos de cuenta activos:** Se retienen mientras el usuario mantenga su cuenta operativa.
    - **Logs de navegación y búsquedas:** Se retienen en almacenamiento rápido por un periodo corto (ej. 90 días) para analítica inmediata, luego se mueven a almacenamiento en frío (Amazon S3 Glacier) para auditorías, y finalmente se eliminan al cumplir su periodo legal.
    - **Eliminación (Derecho al olvido bajo GDPR):** Cuando un usuario solicita el cierre de su cuenta, sus datos entran en una política de retención temporal (usualmente 30 días) por seguridad. Cumplido este plazo, los datos personales se purgan definitivamente tanto de HDFS como de la nube.

5.2. Estrategias de Gobierno de Datos y Gobernanza: Seguridad, Calidad y Disponibilidad

Es imperativo establecer un gobierno de datos riguroso. Para administrar este gobierno y asegurar el cumplimiento de las políticas, se propone la integración de herramientas como **Apache Atlas** (para la catalogación, trazabilidad y linaje de datos) y **Apache Ranger** (para la gestión centralizada de seguridad y control de accesos).

Siguiendo los procedimientos de seguridad de la información, el gobierno se estructura en la tríada **CID**:

- **Confidencialidad:** Se garantiza el manejo ético y privado de los datos de los usuarios. Tras enfrentar una demanda que resultó en el pago de 13 millones de dólares , SoftTech Solutions transparenta sus procesos indicando explícitamente el uso de contactos. Técnicamente, herramientas como Apache Ranger aseguran controles de acceso estrictos y encriptación en los clústeres de Hadoop para evitar accesos no autorizados.
- **Integridad:** Se asegura que la "montaña de datos" no sea alterada de forma indebida y mantenga su precisión. Apache Atlas permite rastrear el ciclo del dato para garantizar que los procesos de limpieza en la ingesta entreguen información fidedigna a los algoritmos de Machine Learning, evitando sugerencias erróneas.
- **Disponibilidad:** Se asegura el acceso ininterrumpido a la información. SoftTech Solutions utiliza centros de datos múltiples, lo cual es extremadamente importante para garantizar una disponibilidad alta y evitar fallos de componentes individuales. La arquitectura en sí misma (Kafka + Hadoop) actúa como respaldo ante caídas.

6. Análisis de la Problemática vs. Arquitectura Seleccionada

La problemática principal de SoftTech Solutions radica en el crecimiento masivo de datos (pasando de 2.700 miembros iniciales a más de 410 millones) y la necesidad de procesar esta información para generar percepciones útiles sin comprometer el rendimiento. Para resolver esto, la Arquitectura Lambda propuesta se adapta perfectamente a sus necesidades.

6.1. Elementos Requeridos y No Requeridos en el flujo de SoftTech Solutions .

Al asociar la problemática con la arquitectura de referencia, identificamos los componentes críticos:

- **Elementos Requeridos:**
  - **Múltiples centros de datos:** Extremadamente importantes para garantizar una disponibilidad alta y evitar fallos de componentes individuales.
  - **Sistemas de alta escalabilidad (Hadoop):** Proporciona la potencia del back-end necesaria para hacer frente a los volúmenes de datos mediante búsquedas por lote.
  - **Herramientas de código abierto propias:** Tecnologías como Kafka, Voldemort, Espresso y Pinot son esenciales, ya que la empresa considera que el código abierto crea mejores productos a largo plazo.
- **Elementos No Requeridos (o que podrían faltar/excluirse):**
  - **Arquitectura puramente Kappa (Solo Real-Time):** No es factible. SoftTech Solutions depende de analizar el historial laboral profundo (ej. una empresa en la que el usuario trabajó hace ocho años), lo cual es costoso de procesar solo en flujos y requiere una capa Batch robusta.
  - **Almacenes de datos tradicionales monolíticos:** El enfoque tradicional de recoger datos y almacenarlos en una base de datos para analizarlos posteriormente no es suficiente por sí solo, ya que generaría cuellos de botella ante millones de búsquedas por segundo.

6.2. Identificación de Necesidades Batch vs. Real-Time.

SoftTech Solutions no puede sobrevivir con un solo enfoque; **requiere obligatoriamente una combinación de ambas (Batch y Real-Time)**:

1. **Necesidad de Procesamiento por Lote (Batch):** Es vital para entrenar los modelos de aprendizaje automático y los algoritmos que calculan sugerencias complejas, como la función "Gente que podrías conocer", cruzando datos históricos de empleos anteriores y conexiones compartidas.
2. **Necesidad de procesamiento en Tiempo Real (Streaming):** SoftTech Solutions utiliza tecnología de procesamiento de flujos para garantizar que la información más actualizada se muestre mientras el usuario navega. Esto incluye transmitir datos directamente de la fuente para notificar quién se ha unido al sitio, nuevos puestos de trabajo o quién ha visto su perfil recientemente.

6.3. Beneficios de la Arquitectura Aplicada según sus Aspectos Característicos.

A continuación, se resumen los beneficios directos de la arquitectura elegida para resolver los requerimientos de la industria:

Aspecto Característico	Beneficio en la Arquitectura Aplicada a SoftTech Solutions
1. Objetivos Comerciales	Aumenta los ingresos (superiores a 700 millones USD) al comprender los clics de los usuarios , informando a los anunciantes para que la publicidad (20-25% de los ingresos) sea más efectiva.
2. Escalabilidad	Permite gestionar una infraestructura con miles de máquinas ejecutando MapReduce , soportando millones de búsquedas por segundo y decenas de miles de páginas servidas.
3. Optimización en el Procesamiento	Acelera el procedimiento analítico mediante el procesamiento de flujos , analizando la actividad del usuario al mismo tiempo que ocurre, sin esperar procesos nocturnos.
4. Seguridad y Privacidad	Garantiza la Confidencialidad, Integridad y Disponibilidad (CID) integrando herramientas de gobierno corporativo directamente en las capas de datos, asegurando el cumplimiento normativo y la confianza del usuario.

1. Big Data como Motor de Negocio Los datos no son solo soporte tecnológico; son el núcleo que permite a SoftTech Solutions monetizar y crecer continuamente.
CONCLUSIONES DE ESTA ETAPA DE ANÁLISIS
2. Eficiencia de la Arquitectura Híbrida El Modelo Lambda (Batch + Streaming) demuestra ser la solución óptima para entregar personalización masiva sin perder velocidad.
3. Ética como Requisito Crítico La privacidad y el gobierno de datos son obligaciones. Sin la confianza del usuario, el ecosistema colapsa.

7. Conclusiones

En conclusión, el análisis del ecosistema de SoftTech Solutions demuestra fehacientemente cómo la implementación de tecnologías de Big Data es el pilar fundamental para sostener y escalar una red profesional a nivel global. El proyecto cumple con todas las características de las "3Vs" (Volumen masivo, Variedad de formatos y Velocidad de flujos), lo que justifica plenamente la adopción de soluciones distribuidas por sobre las bases de datos relacionales tradicionales.

La propuesta de una Arquitectura Lambda resulta ser la decisión técnica más acertada para este contexto. Al combinar una capa de procesamiento por lote (Batch) respaldada por Hadoop, SoftTech Solutions logra analizar el vasto historial de sus 410 millones de usuarios para entrenar modelos predictivos y algoritmos de Machine Learning. Al mismo tiempo, la capa de velocidad (Speed Layer) gestionada mediante tecnologías de Streaming como Kafka y Spark, asegura que los usuarios reciban notificaciones y actualizaciones en tiempo real, garantizando el *engagement* y la inmediatez que exige el mercado actual.

Finalmente, el caso evidencia que el éxito técnico debe ir obligatoriamente acompañado de un estricto Gobierno de Datos. Las multas millonarias enfrentadas por la compañía subrayan que la privacidad, la transparencia y la seguridad de la información no son elementos secundarios, sino requisitos críticos. Un ciclo de vida del dato bien definido, desde su ingesta hasta su archivamiento, asegura la calidad de los modelos analíticos, protege la integridad de los usuarios y permite que la organización siga monetizando su plataforma de manera ética y altamente rentable.

8. Anexos y Bibliografía

Referencias Bibliográficas y Documentales:

1. **Caso de Estudio Principal:** *SoftTech Solutions : Cómo se utiliza Big Data para estimular el éxito de las redes sociales*. Extraído del material "Big Data en la Práctica" (Págs. 87-92).
2. **Material Académico Duoc UC:** *Clase 3 - Introducción al Ecosistema Big Data (On-Premise vs. Cloud y Herramientas Clave)*. Documento de estudio, Ingeniería en Informática.
3. **Material Académico Duoc UC:** *Clase 4 - Arquitecturas de Big Data (Lambda, Kappa, Data Lake, Data Warehouse y Machine Learning)*. Documento de estudio, Ingeniería en Informática.
4. **Documento de Evaluación:** *Rúbrica de Evaluación Parcial N° 1: Conociendo Big Data, Conceptos y Aplicación general*. Subdirección de Diseño Instruccional, Duoc UC.
5. **Herramientas de Apoyo y Estructuración:** *Google Gemini (Inteligencia Artificial)*. Modelo de lenguaje utilizado como asistente técnico para la síntesis de información, estructuración del informe, diseño de la arquitectura Lambda en Draw.io y redacción formal bajo estándares de ingeniería.