



# INGENIERÍA DE SOLUCIONES CON INTELIGENCIA ARTIFICIAL

ISY0101 - 002D  
San Bernardo

## INFORME TRANSVERSAL

SoftTech Solutions

Felipe Monsalve  
Gabriel Bermar

Docente: Francisco Andres Macaya Matas

[GitHub](#)

07/07/2026

## ÍNDICE DE CONTENIDO

|                                                                               |           |
|-------------------------------------------------------------------------------|-----------|
| <b>ÍNDICE DE CONTENIDO</b>                                                    | <b>2</b>  |
| <b>1. Análisis del caso organizacional</b>                                    | <b>3</b>  |
| 1.1. Contexto de SoftTech Solutions y el problema de soporte técnico          | 3         |
| 1.2. Objetivos de la implementación de IA (SLA, automatización)               | 3         |
| 1.3. Requerimientos específicos y desafíos (Precisión, Privacidad)            | 4         |
| <b>2. Diseño de la solución basada en LLM y RAG</b>                           | <b>4</b>  |
| 2.1. Diseño de arquitectura del sistema                                       | 4         |
| 2.2. Implementación del pipeline RAG (Fuentes internas y externas)            | 5         |
| 2.3. Formulación de prompts (System Prompt y mitigación de alucinaciones)     | 6         |
| 2.4. Justificación de decisiones de diseño y elección de modelos/herramientas | 6         |
| <b>3. Desarrollo de agente funcional</b>                                      | <b>7</b>  |
| 3.1. Integración de herramientas de consulta, escritura y razonamiento        | 7         |
| 3.2. Configuración de memoria y recuperación de contexto                      | 7         |
| 3.3. Estrategias de planificación y toma de decisiones del agente             | 8         |
| 3.4. Documentación de la orquestación y el flujo de trabajo automatizado      | 8         |
| <b>4. Implementación de observabilidad, trazabilidad y seguridad</b>          | <b>9</b>  |
| 4.1. Aplicación de métricas de observabilidad                                 | 9         |
| 4.2. Análisis de registros de ejecución y trazabilidad                        | 11        |
| 4.3. Propuesta de rediseño para escalabilidad: IA Verde (Green AI)            | 11        |
| 4.4. Protocolos de seguridad, privacidad y uso responsable                    | 12        |
| <b>5. Conclusiones y Reflexiones Individuales</b>                             | <b>13</b> |
| 5.1. Conclusión General del Proyecto                                          | 13        |
| 5.2. Reflexión Personal - Felipe Monsalve                                     | 14        |
| 5.3. Reflexión Personal - Gabriel Bermar                                      | 14        |
| 5.4. Reflexión Personal - Francisco Andres Macaya Matas                       | 14        |
| <b>6. Referencias Bibliográficas</b>                                          | <b>14</b> |

## 1. Análisis del caso organizacional

### 1.1. Contexto de SoftTech Solutions y el problema de soporte técnico.

SoftTech Solutions es una organización proveedora de un software en la nube (SaaS) especializado en la gestión de inventarios y logística a gran escala, la cual da servicio a una base de más de 500 clientes corporativos. El ecosistema del software es de alta complejidad y se apoya en una extensa documentación técnica que incluye manuales de usuario, guías de integración API y documentos de resolución de errores actualizados constantemente.

El problema crítico que enfrenta la organización es el desbordamiento de su equipo de soporte técnico humano. Actualmente, el 60% de los tickets de soporte ingresados corresponden a consultas operativas recurrentes de Nivel 1 (por ejemplo, "¿Cómo configurar la alerta de stock mínimo?"), cuya información ya se encuentra documentada de manera oficial. Este volumen de consultas repetitivas genera un impacto negativo directo en la calidad del servicio, provocando tiempos de espera de hasta 24 horas para resoluciones simples y saturando al personal técnico, lo que limita su capacidad para atender incidencias de arquitectura o código de mayor complejidad.

### 1.2. Objetivos de la implementación de IA (SLA, automatización).

Para mitigar esta problemática, se propone la implementación de una solución basada en Inteligencia Artificial con el objetivo general de automatizar la resolución de consultas técnicas de Nivel 1 mediante la integración de un agente autónomo en el flujo de atención al cliente.

Los objetivos específicos son:

- **Optimización de SLAs:** Reducir drásticamente el tiempo de respuesta inicial de atención al cliente, pasando de un máximo de 24 horas a una latencia de inferencia inferior a los 10 segundos.
- **Descongestión Operativa:** Filtrar y resolver de manera autónoma al menos el 50% de las consultas básicas, disminuyendo la carga directa sobre los ejecutivos humanos.
- **Fiabilidad:** Garantizar que el 100% de las respuestas generadas sean técnicamente precisas y fundamentadas de manera exclusiva en la documentación oficial provista por la empresa.

### 1.3. Requerimientos específicos y desafíos (Precisión, Privacidad).


El diseño del sistema debe someterse a estrictas reglas de negocio y restricciones técnicas para viabilizar su paso a un entorno de producción corporativo:

- **Precisión Crítica (Mitigación de Alucinaciones):** El modelo tiene estrictamente prohibido generar información, funciones o soluciones que no existan dentro de los manuales proporcionados. Las alucinaciones en este contexto representan un riesgo crítico que degradaría la confianza del cliente.
- **Privacidad y Seguridad de la Información:** Por políticas de protección de datos, el sistema de IA no debe procesar ni almacenar datos sensibles de los clientes corporativos, tales como credenciales de acceso, números de identificación (RUT), correos o información financiera.
- **Trazabilidad de Respuestas:** Es un requerimiento imperativo que cada respuesta entregada por el agente referencie explícitamente su fuente de origen, indicando el documento para que el cliente o supervisor pueda auditar la solución formulada.

## 2. Diseño de la solución basada en LLM y RAG

### 2.1. Diseño de arquitectura del sistema.

La arquitectura diseñada para SoftTech Solutions sigue un patrón híbrido y modular, separando la recuperación de información de la generación de lenguaje para garantizar baja latencia y alta precisión técnica.



El sistema se compone de cuatro pilares fundamentales:

- **Interfaz de Usuario (Frontend):** Desarrollada en Streamlit, actúa como el canal de entrada y salida, desplegando un widget interactivo de chat corporativo.
- **Orquestador (LangGraph):** Es el controlador cognitivo de la aplicación. Evalúa la intención del usuario, enruta la consulta hacia las herramientas correspondientes y administra la memoria de la sesión.
- **Base de Datos Vectorial (VectorDB):** Utilizando ChromaDB, almacena las representaciones numéricas de los documentos para ejecutar búsquedas de similitud semántica ultrarrápidas.
- **Modelo de Lenguaje (LLM):** Motor de procesamiento cognitivo alimentado por Llama 3.3 70B Versatile, encargado exclusivamente de razonar y estructurar la respuesta final basándose en el contexto inyectado.

## 2.2. Implementación del pipeline RAG (Fuentes internas y externas).

Para enriquecer las respuestas del modelo y entregar una asistencia técnica completa, el pipeline de recuperación (RAG) combina estratégicamente dos tipos de fuentes de datos:

1. **Fuentes Internas (Documentación oficial):** El sistema ingesta manuales de usuario (PDF), guías de API y bases de conocimiento histórico. Para preservar la lógica de los manuales y evitar instrucciones paso a paso incompletas, se aplica una Fragmentación Semántica (*Recursive Character Text Splitting*) mediante LangChain. Posteriormente, estos fragmentos son vectorizados utilizando el modelo all-MiniLM-L6-v2 de HuggingFace y almacenados en ChromaDB. Al recibir una consulta, el orquestador recupera únicamente los fragmentos más relevantes (Top-K) mediante similitud del coseno.
2. **Fuentes Externas (APIs en vivo):** Para satisfacer el requerimiento de contexto organizacional dinámico, el pipeline RAG se complementa con llamadas directas a infraestructura externa. Mediante el uso de la librería requests de Python, el agente tiene la capacidad autónoma de consultar el estado de los servidores en la nube (ej. Uptime de AWS) en tiempo real, permitiendo diagnosticar lentitud o caídas masivas sin depender de documentos estáticos.

### 2.3. Formulación de prompts (System Prompt y mitigación de alucinaciones).

Para garantizar que el modelo opere bajo los estrictos parámetros de seguridad de SoftTech Solutions, el *System Prompt* fue diseñado empleando técnicas de enjaulamiento de rol y delimitación de contexto:

*"Eres un asistente de soporte técnico avanzado de Nivel 1 para el software SaaS de SoftTech Solutions. Tu objetivo es resolver problemas de clientes corporativos razonando paso a paso.*

*TIENES ACCESO A HERRAMIENTAS. Antes de responder, PIENSA:*

- 1. ¿La pregunta es sobre cómo hacer algo, manuales o errores? Usa la herramienta 'buscar\_en\_manuales'.*
- 2. ¿El usuario pregunta por tiempos de espera, urgencias o SLAs? Usa la herramienta 'calcular\_tiempo\_respuesta'.*
- 3. ¿Es un problema que no puedes resolver? Usa la herramienta 'redactar\_escalamiento'.*
- 4. ¿El usuario reporta caídas del sistema o pregunta por servidores? Usa la herramienta 'consultar\_estado\_servidor\_externo'.*

*REGLA CRÍTICA: NUNCA inventes información. Debes responder basándote ÚNICA Y EXCLUSIVAMENTE en el contexto proporcionado. Si usas la herramienta de manuales, incluye la cita de la fuente al final."*

Esta estructura mitiga las alucinaciones al bloquear la tendencia probabilística del LLM a inventar soluciones (actuando como un cortafuegos), y exige la trazabilidad al obligar al modelo a extraer y mostrar los metadatos exactos de los documentos recuperados.

### 2.4. Justificación de decisiones de diseño y elección de modelos/herramientas.

La selección del *stack* tecnológico se fundamenta en la eficiencia operativa, el control de costos y el resguardo de la privacidad:

- **LangGraph como Orquestador:** Se prefirió por sobre un flujo lineal estándar debido a su capacidad intrínseca para manejar aplicaciones "stateful" (con estado/memoria), permitiendo flujos de soporte prolongados y la invocación cíclica de herramientas.
- **ChromaDB y HuggingFace (Local):** La ejecución del modelo de embeddings (all-MiniLM-L6-v2) y el almacenamiento en ChromaDB se realizan de forma 100% local. Esto elimina los costos de suscripción cloud y garantiza que la documentación corporativa privada de SoftTech Solutions nunca salga de los servidores de la empresa.

- **Inferencia LLM con Groq (Llama 3.3):** Para cumplir con el SLA crítico de latencia menor a 10 segundos, se descartaron APIs tradicionales en favor de la arquitectura LPU (Language Processing Units) de Groq. Además, el modelo Llama 3.3 70B fue elegido por su comprobada superioridad algorítmica en tareas de *Tool Calling* (uso de herramientas) y razonamiento lógico.

### 3. Desarrollo de agente funcional

#### 3.1. Integración de herramientas de consulta, escritura y razonamiento

Para dotar al sistema de asistencia de autonomía operativa frente a flujos complejos y dinámicos, el agente orquestado en LangGraph integra cuatro capacidades (Tools) diferenciadas por su naturaleza lógica y transaccional:

- **buscar\_en\_manuales (Consulta RAG):** Herramienta que interactúa directamente con la base de datos vectorial ChromaDB. Recibe una cadena de búsqueda semántica y ejecuta un filtrado basado en similitud del coseno para recuperar los fragmentos (*chunks*) más relevantes procedentes de la documentación corporativa no estructurada (manuales de usuario PDF y guías técnicas).
- **calcular\_tiempo\_respuesta (Razonamiento Lógico):** Herramienta de procesamiento interno diseñada para el cálculo determinista de Acuerdos de Nivel de Servicio (SLA). Recibe como entrada parámetros de criticidad ("*alta*", "*media*", "*baja*") y ejecuta la lógica de evaluación y asignación de tiempos máximos permitidos de atención sin consumir recursos de inferencia del LLM ni consultar la base vectorial.
- **redactar\_escalamiento (Escritura / Integración CRM):** Herramienta transaccional que se activa cuando una incidencia excede el alcance del soporte operativo de Nivel 1 o carece de solución documentada. Captura el contexto acumulado de la sesión, formatea un objeto estructurado (identificador, motivo deducido e historial previo) y lo registra de forma persistente en la interfaz del CRM para la derivación al soporte humano de Nivel 2.
- **consultar\_estado\_servidor\_externo (Llamada API en tiempo real):** Herramienta de consulta dinámica a infraestructura externa implementada mediante la librería requests de Python. Permite al agente ejecutar peticiones HTTP a endpoints de monitoreo de nube (por ejemplo, métricas de *Uptime* o latencia de servidores AWS/Azure) para responder de forma autónoma a reportes sobre caídas masivas o problemas de conectividad, desacoplando el diagnóstico de la documentación estática.

### 3.2. Configuración de memoria y recuperación de contexto

Para superar las limitaciones inherentes a la inferencia sin estado (*stateless*) del modelo de lenguaje, la arquitectura integra el módulo MemorySaver de LangGraph.

Cada nueva interacción inicializada desde el *frontend* se asocia a una clave de sesión persistente denominada `thread_id` (generada sistemáticamente mediante la librería `uuid` de Python). A través de este identificador, el grafo conserva el estado de la conversación y actualiza dinámicamente el historial transaccional. En cada turno conversacional, el orquestador inyecta el historial acumulado en la ventana de contexto del modelo de inferencia (Llama 3.3 70B), garantizando que el agente mantenga la coherencia en flujos prolongados, recupere referencias anteriores (como el nombre del usuario o incidencias descritas previamente) y gestione las tareas secuenciales sin pérdida de datos.



háblame sobre el Modelo Lambda



¡Claro! El Modelo Lambda se describe en el contexto proporcionado como la "solución óptima para entregar personalización masiva sin perder velocidad". Esto se menciona en la sección "2. Eficiencia de la Arquitectura Híbrida".

Aquí te presento la solución paso a paso:

1. El Modelo Lambda combina la arquitectura de procesamiento en lote (Batch) con la arquitectura de procesamiento en tiempo real (Streaming).
2. Esto permite entregar personalización masiva sin comprometer la velocidad de procesamiento.
3. El Modelo Lambda es considerado la solución óptima para entregar personalización masiva sin perder velocidad.

Referencia: "2. Eficiencia de la Arquitectura Híbrida" en el contexto proporcionado.

Escribe tu consulta operativa aquí...





### 3.3. Estrategias de planificación y toma de decisiones del agente

La lógica cognitiva del agente se aparta del enrutamiento lineal estándar y adopta el patrón arquitectónico Plan-and-Execute. Bajo este esquema, la ejecución no se realiza de manera monolítica; el orquestador separa el proceso en fases de planificación abstracta y ejecución modular:

1. **Fase de Evaluación Semántica:** Al recibir la consulta natural, el orquestador analiza la intención de fondo y evalúa si la solicitud corresponde a una consulta documental, una duda sobre tiempos de respuesta, un fallo de servidores o una solicitud de escalamiento explícita.
2. **Planificación Secuencial:** El modelo determina el curso de acción óptimo, seleccionando y ordenando las invocaciones a herramientas necesarias de forma autónoma antes de generar la respuesta final.
3. **Evaluación Continua y Auto-corrección:** Si al ejecutar `buscar_en_manuales` el agente evalúa que la información recuperada es insuficiente o imprecisa para el contexto específico de SoftTech Solutions, la lógica del grafo interrumpe la generación intuitiva, descarta la alucinación probabilística y aborta o enruta el flujo de manera controlada hacia `redactar_escalamiento`.

### 3.4. Documentación de la orquestación y el flujo de trabajo automatizado

El ciclo de vida del flujo automatizado en el entorno corporativo se estructura en los siguientes nodos de procesamiento continuo:

1. **Ingreso de Solicitud:** La petición del cliente se recibe por la interfaz Streamlit y se empaqueta junto con su `thread_id`.
2. **Preprocesamiento y Seguridad:** El *middleware* evalúa la consulta para mitigar riesgos de inyección y filtrar patrones de datos personales (PII).
3. **Nodo de Orquestación (LangGraph):** El grafo recibe el prompt limpio y el historial del MemorySaver. Se activa el motor de inferencia con el *System Prompt* enjaulado.
4. **Ejecución de Herramientas (Tool Calling):** Si la intención requiere datos adicionales, el nodo despacha la acción hacia el componente correspondiente (`buscar_en_manuales`, `calcular_tiempo_respuesta`, `consultar_estado_servidor_externo` o `redactar_escalamiento`).
5. **Síntesis y Grounding:** Con el resultado de la herramienta inyectado en la ventana de contexto, el modelo formula la respuesta final técnica adjuntando las referencias de trazabilidad (*Grounding*) hacia el manual o API de origen.
6. **Retorno y Persistencia:** La respuesta final se entrega en el *frontend* y el estado de la transacción se escribe en el nodo de memoria (MemorySaver) para el siguiente turno.


## 4. Implementación de observabilidad, trazabilidad y seguridad

### 4.1. Aplicación de métricas de observabilidad

Para abandonar el paradigma del modelo como "caja negra" en el paso a producción, el backend integra la plataforma LangSmith habilitada mediante variables de entorno (LANGCHAIN\_TRACING\_V2=true). La telemetría captura de manera sistemática tres dimensiones operativas críticas alineadas con los SLA corporativos:

- **Latencia e Inferencia:** Se monitorea el tiempo total de ciclo (*run*). El percentil 50 (**P50**) evalúa la experiencia estándar del usuario (con métrica objetivo  $<10\text{ s}$ ), logrando promedios estables en el rango de los  $1.14\text{ s}$  a  $1.6\text{ s}$  en flujos resueltos), mientras que el percentil 90/99 (**P90/P99**) audita escenarios atípicos o cadenas con invocación múltiple de herramientas.
- **Consumo de Recursos (Uso de Tokens):** Se traza la proporción entre *Prompt Tokens* (contexto inyectado y fragmentos RAG) y *Completion Tokens* (salida generada). Esto permite evaluar los sobrecostos y la saturación computacional del sistema.
- **Precisión, Consistencia y Tasa de Resolución Nivel 1:** Se audita la estabilidad en la ejecución del *Tool Calling* y la capacidad de resolución autónoma. La Tasa de Resolución N1 cuantifica el porcentaje de sesiones cerradas con éxito sin activar la herramienta redactar\_escalamiento (manteniéndose en niveles de operación del  $85\%$ ).

Esta analítica se refleja en el Dashboard de Monitoreo implementado en el *frontend* con Streamlit. La arquitectura visual se estructura bajo un enfoque de *Progressive Disclosure*: un panel superior expone tarjetas de KPI globales en tiempo real (Latencia P50, Consumo de Tokens, Tasa de Resolución N1), acompañado por una barra lateral (*sidebar*) para la segmentación del análisis por fecha o *thread\_id*. Adicionalmente, una vista tipo CRM enlista en un *Dataframe* interactivo los escalamientos generados con su ID de ticket, prioridad y motivo deducido por la IA.



## 4.2. Análisis de registros de ejecución y trazabilidad

La inspección de trazas (*traces*) en LangSmith permitió auditar el árbol de llamadas interno, verificando paso a paso las rutas del agente y el enrutamiento del patrón *Plan-and-Execute*. Las pruebas empíricas bajo estrés demostraron que cuando se somete el sistema a consultas ambiguas, los *logs* registran el razonamiento interno donde el modelo reconoce la falta de especificidad paramétrica y decide invocar *buscar\_en\_manuales* para fundamentar su salida, evitando alucinaciones.

No obstante, el análisis de trazabilidad identificó una anomalía de riesgo en flujos conversacionales extensos: la saturación progresiva de la ventana de contexto. Al inspeccionar los *logs*, se evidenció que inyectar de forma reiterada el historial íntegro del MemorySaver junto con los nuevos fragmentos vectoriales recuperados en cada turno provocaba un aumento lineal exponencial en el consumo de *tokens*. Esta acumulación generó dos cuellos de botella computacionales:


1. Elevación de la latencia P90 por sobre el SLA admisible debido al procesamiento de prompts masivos.
2. Dilución de la atención semántica, disminuyendo la precisión de la recuperación RAG y causando desvíos en la instrucción principal.

| P50 Latency | P99 Latency | Tokens   | C |
|-------------|-------------|----------|---|
| 🕒 0.77s     | 🕒 1.29s     | 📊 10,504 |   |
| 🕒 1.17s     | 🕒 1.17s     | 📊 2,356  |   |
| 🕒 0.74s     | 🕒 0.74s     | 📊 1,064  |   |
| 🕒 1.14s     | 🕒 1.14s     | 📊 1,059  |   |
| 🕒 1.61s     | 🕒 1.61s     | 📊 2,558  |   |
| 🕒 1.67s     | 🕒 1.67s     | 📊 5,008  |   |
| 🕒 1.45s     | 🕒 1.45s     | 📊 1,227  |   |
| 🕒 0.74s     | 🕒 0.74s     | 📊 1,149  |   |
| 🕒 1.61s     | 🕒 1.61s     | 📊 2,456  |   |

### 4.3. Propuesta de rediseño para escalabilidad: IA Verde (Green AI)

Con base en los cuellos de botella diagnosticados por la telemetría, se proyectó un rediseño del sistema orientado a la optimización de recursos bajo el paradigma de **IA Verde**:



- **Caché Semántico en Memoria:** Se propone la implementación de una capa intermedia (ChromaSemanticCache) que intercepta la consulta vectorizada antes de activar el grafo. Si la similitud del coseno respecto a una pregunta histórica ya resuelta supera un umbral riguroso ( $\text{score\_threshold} > 0.95$ ), la arquitectura devuelve de manera inmediata la respuesta almacenada en caché. Esto suprime la inferencia redundante en el LLM de Groq, hace descender la latencia operativa a orden de milisegundos y disminuye drásticamente el consumo de *tokens* y la huella de carbono.
- **Algoritmo MMR (Maximal Marginal Relevance):** Para mitigar la saturación por acumulación de vectores, se propone reemplazar la búsqueda clásica por similitud pura (*Top-K*) en la base vectorial por el algoritmo MMR. Este método maximiza la relevancia de los fragmentos recuperados y penaliza la redundancia computacional, garantizando la inyección de contexto heterogéneo.
- **Compresión Dinámica de Memoria:** Se plantea integrar un nodo de compresión (*SummaryNode*) previo a la persistencia en MemorySaver. Cuando el hilo conversacional supera el umbral preestablecido de  $2048 \text{ tokens}$ , este proceso asíncrono resume el historial anterior, reteniendo el estado lógico sin sobrecargar la ventana de atención del modelo de inferencia.



#### 4.4. Protocolos de seguridad, privacidad y uso responsable

El despliegue en el ecosistema corporativo de SoftTech Solutions incorpora una arquitectura de ciberseguridad estructurada en dos capas defensivas perimetrales e internas:

- **Middleware de Protección de Datos Sensibles (Filtro PII):** Como mecanismo de prevención contra la fuga de datos confidenciales y en estricto cumplimiento normativo, se interpuso una capa intermedia de anonimización activa entre el *frontend* y el orquestador. Utilizando expresiones regulares (Regex) y técnicas de NLP pre-procesamiento, el filtro escanea la entrada del cliente para identificar y enmascarar formatos de RUT nacionales válidos, correos electrónicos y credenciales numéricas financieras (reemplazándolos por etiquetas neutras como [RUT\_CENSURADO] o [CORREO\_CENSURADO]). De este modo, la información sensible no alcanza las API de inferencia externas ni queda almacenada en la telemetría de LangSmith.
- **Prevención de *Prompt Injection*:** Para anular ataques de manipulación de instrucciones imperativas orientadas a evadir directrices o extraer el *System Prompt*, se enjauló el modelo configurando delimitaciones de contexto (*Context Boundaries*) estricta. Las directrices prohíben categóricamente el uso de conocimiento paramétrico ajeno a la documentación local. Adicionalmente, el esquema *Plan-and-Execute* evalúa semánticamente la consulta de entrada. Ante detecciones de inyección maliciosa ("*olvidate de tus instrucciones anteriores*"), el orquestador aborta la cadena de inferencia de manera preventiva y gatilla un rechazo estandarizado o activa la derivación a seguridad por medio de la herramienta *redactar\_escalamiento*.



## 5. Conclusiones y Reflexiones Individuales

### 5.1. Conclusión General del Proyecto

La ingeniería de solución planteada para SoftTech Solutions consolida una arquitectura de asistencia corporativa madura, escalable y segura, cumpliendo a cabalidad con los objetivos operacionales de reducción de latencias y alta tasa de resolución autónoma. La integración de un *stack* modular (LangGraph como motor de estado, ChromaDB y HuggingFace para indexación local, y Llama 3.3 en infraestructura Groq LPU) demostró que es viable desacoplar flujos repetitivos de soporte Nivel 1 sin sacrificar la precisión ni la privacidad corporativa.

Asimismo, la incorporación del componente de observabilidad mediante LangSmith permitió auditar empíricamente el comportamiento del sistema, revelando de forma proactiva riesgos de saturación de contexto en flujos largos. La formulación de mejoras arquitectónicas bajo el paradigma de IA Verde —tales como la adopción de Caché Semántico, filtrado MMR y nodos de compresión— asegura la sostenibilidad económica y computacional de la plataforma para absorciones masivas de carga. Sumado a las capas de ciberseguridad PII y anti-inyección de prompts, la solución se posiciona como una herramienta robusta para el despliegue en entornos corporativos de producción.

### 5.2. Reflexión Personal - Felipe Monsalve

Al armar este proyecto me encontré con varios problemas que me sirvieron para aprender. Lo primero fue hacer una buena arquitectura en el entorno virtual; me costó dejarlo funcionando bien, pero me quedó claro que si no trabajas de forma ordenada desde el principio, después el código es un desastre.

Un cambio importante fue dejar de lado la API de OpenAI para usar HuggingFace y Groq. Fue una buena decisión porque, además de ahorrar plata, me di cuenta de que se pueden hacer cosas potentes sin depender de empresas externas. Lo más difícil fue el tema de las alucinaciones de la IA. En una empresa no puedes dejar que un bot invente cualquier cosa porque quedas mal con los clientes. Por eso, lo que más me costó pero logré hacerlo fue "enjaular" al modelo para que sea confiable y no responda tonteras.

### 5.3. Reflexión Personal - Gabriel Bernal

Para mí, este proyecto dejó claro lo importante que es trabajar en equipo usando Git y GitHub. Cuando tuvimos problemas al mezclar los cambios del repositorio y aprendimos a resolverlos, se notó lo necesario que es eso en un contexto real. También nos permitió ir integrando el trabajo sin desordenarnos y entender mejor cómo coordinar el código entre los dos.

Por otro lado, los prompts me hicieron cambiar de vista la forma en que veía la IA. Me di cuenta de que no se trata solo de usarla, sino de saber cómo pedirle las cosas, con instrucciones claras, para que entregue justo lo que uno necesita. Mientras más preciso eres, mejor funciona. Al final, esto me hizo pensar en el soporte técnico a futuro. Herramientas como la que hicimos no vienen a reemplazar a las personas, sino a ayudar con tareas repetitivas. Así, el trabajo se enfoca más en analizar problemas y tomar decisiones, donde el criterio humano sigue siendo importante.

## 6. Referencias Bibliográficas

Chroma. (2024). *ChromaDB Documentation: The AI-native open-source embedding database*. <https://docs.trychroma.com/>

Groq. (2024). *Groq Cloud Documentation: Llama 3 Inference on LPU Architecture*. <https://console.groq.com/docs>

Hugging Face. (2024). *Sentence-Transformers: all-MiniLM-L6-v2 model*. <https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2>

LangChain. (2024a). *LangChain Documentation: Retrieval-Augmented Generation (RAG)*. [https://python.langchain.com/docs/use\\_cases/question\\_answering/](https://python.langchain.com/docs/use_cases/question_answering/)

LangChain. (2024b). *LangGraph Documentation: Building Stateful Multi-Actor Applications*. <https://langchain-ai.github.io/langgraph/>

LangChain. (2024c). *LangSmith Documentation: Tracing and Observability for LLM Applications*. <https://docs.smith.langchain.com/>

Streamlit. (2024). *Streamlit API Reference: Building Chat Interfaces and Dashboards*. <https://docs.streamlit.io/>